

Universidad Tecnológica de la Mixteca

Instituto de Computación

Ingeniería en Computación

**Clasificación de Niveles de Ansiedad, Estrés
y Depresión mediante Modelos de
Bayes Ingenuo y Árboles de Decisión**

Materia: Reconocimiento de Patrones

Alumno:

José Ramón Aragón Toledo

Índice

1. Introducción	2
2. Preprocesamiento de Datos	2
2.1. Carga y verificación de calidad	2
2.2. Distribución de la variable objetivo	3
2.3. Discretización por Ancho Constante (<i>Equal Width</i>)	3
2.4. Escalado y división de datos	3
3. Metodología de Clasificación — Tarea 1	4
3.1. Modelos utilizados	4
3.2. Resultados — Tarea 1	4
3.3. Matrices de Confusión	5
4. Selección de Características — Tarea 2	5
4.1. Información Mutua (MMI)	5
4.2. Contraste con el Factor de Fisher	5
4.3. Ranking MMI — Ansiedad y Depresión	6
4.4. Entrenamiento con Top-10 MMI	8
5. Análisis Comparativo de Resultados	9
5.1. Hallazgo central: <code>blood_pressure</code> como predictor universal	9
6. Conclusiones	9

1. Introducción

El bienestar mental estudiantil es un área de creciente interés en sistemas educativos a nivel mundial. La detección temprana de niveles elevados de ansiedad, estrés y depresión puede permitir intervenciones oportunas que mejoren el rendimiento académico y la calidad de vida de los estudiantes.

El presente reporte documenta el proceso completo de clasificación multiclase aplicado al conjunto de datos *StressLevelDataset.csv*, el cual comprende **1 100 registros** de estudiantes con **20 variables** de naturaleza fisiológica, psicológica, social y ambiental. La variable objetivo principal es `stress_level`, codificada en tres clases: **Bajo (0)**, **Medio (1)** y **Alto (2)**.

Los objetivos del proyecto son:

1. Construir modelos de clasificación usando *Gaussian Naive Bayes* y *Decision Tree Classifier* con todas las variables disponibles (**Tarea 1**).
2. Aplicar selección de características mediante **Información Mutua (MMI)** y comparar el desempeño con el subconjunto reducido (**Tarea 2**).
3. Identificar los predictores más relevantes para los niveles de **ansiedad** y **depresión** mediante el análisis de los rankings obtenidos.

Todos los experimentos se implementaron con `Python 3.12` y la biblioteca `scikit-learn 1.8`, garantizando reproducibilidad mediante `random_state = 42`.

2. Preprocesamiento de Datos

2.1. Carga y verificación de calidad

El conjunto de datos fue inspeccionado formalmente con la biblioteca `pandas`. Los resultados de la auditoría de calidad se resumen a continuación:

- **Valores nulos:** 0 en las 21 columnas (20 variables + 1 objetivo).
- **Filas duplicadas:** 0.
- **Tipos de datos:** todos enteros (`int64`), sin requerir codificación adicional.

2.2. Distribución de la variable objetivo

La Tabla 1 muestra que las tres clases presentan una distribución prácticamente uniforme ($\approx 33\%$ cada una), condición que garantiza que los modelos no estén sesgados por desbalance de clases.

Cuadro 1: Distribución de la variable objetivo `stress_level`

Clase	Frecuencia	Porcentaje (%)
Bajo (0)	373	33.91
Medio (1)	358	32.55
Alto (2)	369	33.55
Total	1 100	100.00

2.3. Discretización por Ancho Constante (*Equal Width*)

Previo al análisis de selección de características, las variables `anxiety_level`, `self_esteem` y `depression` fueron discretizadas mediante el método de **Ancho Constante** (*Equal Width Binning*), el cual divide el rango continuo de cada variable en k intervalos de igual amplitud. Este paso tiene dos objetivos:

1. Reducir el ruido en variables con alta variabilidad dentro de una misma clase.
2. Hacer explícita la naturaleza ordinal de estas variables, lo que mejora la estimación de la Información Mutua en pasos posteriores.

Para cada variable X con rango $[X_{\min}, X_{\max}]$ y k intervalos, el ancho de cada bin se calcula como:

$$w = \frac{X_{\max} - X_{\min}}{k} \quad (1)$$

2.4. Escalado y división de datos

Se aplicó **StandardScaler** para normalizar las escalas de las características, transformando cada variable a media $\mu = 0$ y desviación estándar $\sigma = 1$:

$$z = \frac{x - \mu}{\sigma} \quad (2)$$

El escalador se ajustó *únicamente* sobre el conjunto de entrenamiento y se aplicó a ambos conjuntos para evitar fuga de información (*data leakage*).

La división **Hold-out** se realizó con los parámetros de la Tabla 2.

Cuadro 2: Parámetros y resultados del split Hold-out

Parámetro	Valor	Muestras
Entrenamiento	70 %	770
Prueba	30 %	330
random_state	42	—
stratify	y	—

3. Metodología de Clasificación — Tarea 1

3.1. Modelos utilizados

Se entrenaron dos algoritmos de clasificación con las **20 variables** completas del dataset:

- **Gaussian Naive Bayes (GaussianNB)**: clasificador probabilístico basado en el teorema de Bayes que asume independencia condicional entre características y distribución gaussiana por clase. Su fortaleza radica en su eficiencia computacional y su buen desempeño incluso con datos de tamaño moderado.
- **Decision Tree Classifier** con `max_depth = 6`: árbol de decisión cuya profundidad máxima fue acotada para controlar el sobreajuste (*overfitting*), favoreciendo la generalización sobre el conjunto de prueba.

3.2. Resultados — Tarea 1

La Tabla 3 presenta las métricas de evaluación ponderadas por clase obtenidas sobre el 30 % de datos de prueba.

Cuadro 3: Métricas de clasificación — Tarea 1 (20 variables)

Modelo	Accuracy	Precision	Recall	F1-Score
Gaussian Naive Bayes	88.18 %	0.8990	0.8818	0.8837
Decision Tree (depth=6)	88.48 %	0.8853	0.8848	0.8849

Ambos modelos superan el **88 %** de exactitud, confirmando la alta separabilidad de las clases en este conjunto de datos. Un hallazgo destacado es que el modelo Gaussian Naive Bayes alcanzó un **Recall = 0.96** para la clase *Alto (2)*, identificando correctamente el 96 %

de los casos de estrés elevado, propiedad especialmente valiosa en contextos de detección temprana.

3.3. Matrices de Confusión

Cuadro 4: Matriz de Confusión — Gaussian Naive Bayes (Tarea 1)

Real \ Predicho	Bajo (0)	Medio (1)	Alto (2)
Bajo (0)	94	0	18
Medio (1)	3	90	14
Alto (2)	4	0	107

Cuadro 5: Matriz de Confusión — Decision Tree (Tarea 1)

Real \ Predicho	Bajo (0)	Medio (1)	Alto (2)
Bajo (0)	98	5	9
Medio (1)	5	95	7
Alto (2)	6	6	99

4. Selección de Características — Tarea 2

4.1. Información Mutua (MMI)

La **Información Mutua** cuantifica la dependencia estadística entre una variable aleatoria X y la variable objetivo Y , capturando tanto relaciones lineales como no lineales:

$$I(X; Y) = \sum_{y \in Y} \sum_{x \in X} p(x, y) \log \left(\frac{p(x, y)}{p(x) p(y)} \right) \quad (3)$$

Un valor $I(X; Y) = 0$ indica independencia estadística, mientras que valores mayores indican mayor capacidad predictiva de X sobre Y . Se calculó mediante `mutual_info_classif` de `scikit-learn`, ajustado *únicamente* sobre el conjunto de entrenamiento.

4.2. Contraste con el Factor de Fisher

Para validar la selección, los resultados de MMI se contrastaron con el **Factor de Fisher** (ANOVA F-value), que cuantifica la separación entre medias de clase en función de la varianza intra-clase:

$$F = \frac{\text{Varianza entre clases}}{\text{Varianza intra-clase}} \quad (4)$$

La comparación reveló que ambos métodos coinciden en **3 de las 5** primeras posiciones. La principal discrepancia es `academic_performance` (Fisher: posición 4, MMI: posición 13), lo que indica que esta variable tiene una separación lineal de medias alta pero baja capacidad discriminante no lineal. Dado que el dataset tiene variables discretas y ordinales, se concluye que **MMI es el criterio más adecuado** para este tipo de datos.

4.3. Ranking MMI — Ansiedad y Depresión

La Tabla 6 presenta el Top 5 de variables más informativas para los targets `anxiety_level` y `depression`.

Cuadro 6: Top 5 — Ranking MMI por target

Pos.	Característica	MI (Ansiedad)	MI (Depresión)
1	<code>blood_pressure</code>	0.7473	0.7977
2	<code>bullying</code>	0.7193	—
3	<code>sleep_quality</code>	0.6981	0.7209
4	<code>future_career_concerns</code>	—	—
5	<code>self_esteem</code>	—	—
2 (Dep.)	<code>sleep_quality</code>	—	0.7209
3 (Dep.)	<code>anxiety_level</code>	—	0.6935

Las figuras 1 y 2 muestran el ranking completo de las 19 variables para cada target, ordenadas de mayor a menor importancia.




Figura 1: Ranking de Información Mutua — Target: Nivel de Ansiedad




Figura 2: Ranking de Información Mutua — Target: Nivel de Depresión

4.4. Entrenamiento con Top-10 MMI

Se seleccionaron las **10 variables** con mayor score MMI respecto a **stress_level** y se volvieron a entrenar ambos modelos. La Tabla 7 muestra los resultados obtenidos.

Cuadro 7: Métricas de clasificación — Tarea 2 (Top-10 MMI)

Modelo	Accuracy	Precision	Recall	F1-Score
Gaussian Naive Bayes	87.27 %	0.8943	0.8727	0.8752
Decision Tree (depth=6)	86.97 %	0.8697	0.8697	0.8696

5. Análisis Comparativo de Resultados

La Tabla 8 consolida las métricas de ambas tareas para facilitar la comparación directa entre el uso de todas las variables y el subconjunto reducido por MMI.

Cuadro 8: Comparación Tarea 1 (todas las variables) vs. Tarea 2 (Top-10 MMI)

Modelo	Accuracy		F1-Score (weighted)	
	Tarea 1	Tarea 2	Tarea 1	Tarea 2
Gaussian Naive Bayes	88.18 %	87.27 %	0.8837	0.8752
Decision Tree (depth=6)	88.48 %	86.97 %	0.8849	0.8696

Los resultados muestran que la reducción del 50 % de las variables (de 20 a 10) provocó una disminución de exactitud de únicamente:

- $\Delta \text{Acc}_{\text{NB}} = -0.91 \%$
- $\Delta \text{Acc}_{\text{DT}} = -1.51 \%$

Este resultado confirma que las 10 variables descartadas aportaban información redundante o de baja discriminancia, y que el ranking MMI identificó correctamente el núcleo informativo del dataset.

5.1. Hallazgo central: blood_pressure como predictor universal

La variable `blood_pressure` obtuvo el **primer lugar** en los tres rankings calculados (stress, ansiedad y depresión), con scores MMI superiores a 0.74 en todos los casos. Esto sugiere que la presión arterial es el indicador fisiológico más fuertemente correlacionado con el bienestar mental en esta muestra estudiantil, lo que es coherente con la literatura médica sobre la conexión entre el sistema nervioso autónomo y los estados de estrés crónico.

6. Conclusiones

A partir del análisis realizado se derivan las siguientes conclusiones:

1. **Alta precisión base.** Ambos modelos, Gaussian Naive Bayes y Decision Tree, alcanzan más del **88 %** de exactitud con las 20 variables completas, demostrando que el dataset presenta patrones de clase bien definidos y separables.
2. **Robustez ante reducción de dimensionalidad.** La selección por Información Mutua permitió reducir el espacio de características en un **50 %** con una caída máxima de exactitud de apenas **1.5 %** (Decision Tree). Este resultado valida la eficiencia del ranking MMI como método de selección de características para datos discretos y ordinales.

3. **Recall destacado en detección de estrés alto.** Gaussian Naive Bayes mantuvo un Recall de **96%** para la clase *Alto (2)* en ambas tareas, propiedad crítica para aplicaciones de detección temprana donde un falso negativo tiene mayor costo que un falso positivo.
4. **Superioridad de MMI sobre Fisher para datos ordinales.** El contraste entre ambos métodos de ranking reveló discrepancias significativas (p. ej., `academic_performance`: Fisher #4 vs. MMI #13), confirmando que el Factor de Fisher sobrevalora variables con alta separación lineal de medias pero baja capacidad discriminante no lineal.
5. **Predictor universal: blood_pressure.** Esta variable lideró los tres rankings de importancia (stress, ansiedad y depresión), posicionándose como el predictor fisiológico central del bienestar mental en el contexto estudiantil analizado.

Referencias

- [1] Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
- [2] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [3] Cover, T. M. & Thomas, J. A. (2006). *Elements of Information Theory* (2a ed.). Wiley-Interscience.
- [4] Quinlan, J. R. (1986). Induction of Decision Trees. *Machine Learning*, 1(1), 81–106.
- [5] Shannon, C. E. (1948). A Mathematical Theory of Communication. *Bell System Technical Journal*, 27, 379–423.